La Evolución de la Ciencia de Datos hacia la Computación Cuántica: Análisis de la Ventaja Cuántica en Casos Aplicados

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica · UNIR

Director: Ricardo Rafael Domínguez Reyes

unir LA UNIVERSIDAD EN INTERNET

ÍNDICE

01 – Introducción

02 – Motivación

03 – Objetivos

04 – Contexto y estado de la técnica

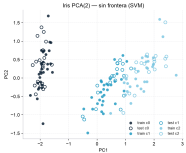
05 – Resultados y análisis

06 – Conclusiones

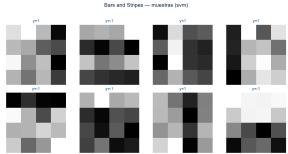
07 – Líneas futuras de investigación

Introducción
Dos familias de problemas, seis datasets

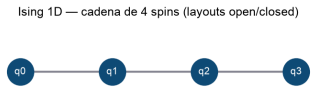
¿Mejoran los métodos cuánticos, simulados con pocos qubits, la calidad o el coste frente a los clásicos?



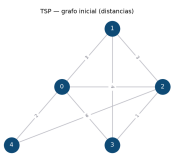
Iris: dato convencional



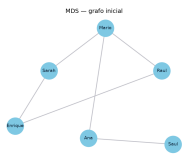
Bars and Stripes: patrones 4×4



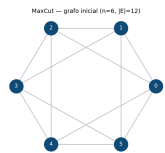
Ising: dato de sistema



TSP: 5 nodos

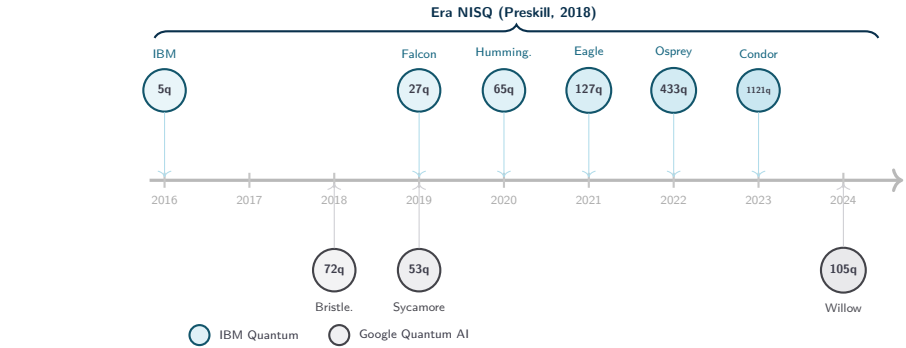


MDS: 6 vértices



MaxCut (HamLib): 6 vértices

Motivación
Mucha promesa, poca evidencia comparable



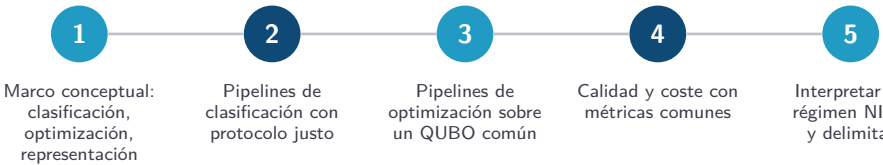
Promesa: kernels en espacios de Hilbert grandes y QAOA/VQE en hardware NISQ (Havlíček et al., 2019; Farhi et al., 2014)

Evidencia: con protocolo justo, los clásicos suelen igualar o ganar (Bowles et al., 2024; Yu et al., 2026)

Objetivos

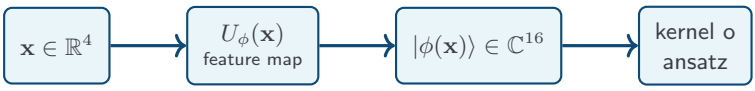
Objetivo general

Evaluar de forma empírica si los algoritmos cuánticos NISQ ofrecen ventaja medible frente a los clásicos en clasificación y optimización.

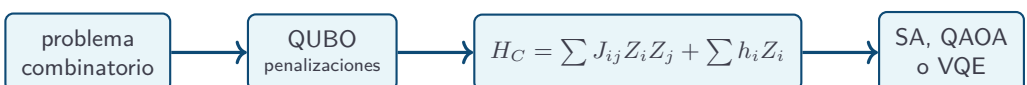


Contexto y estado de la técnica
La representación como puente

Clasificación



Optimización



El feature map y el QUBO fijan el espacio en el que opera el método cuántico (Lloyd et al., 2020; Lucas, 2014).

Contexto y estado de la técnica
Estado de la técnica

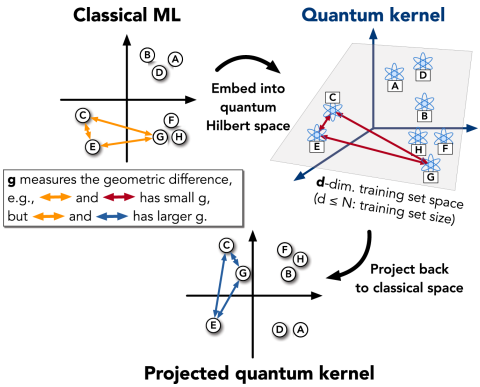


Fig. 2 de Huang et al. (2021), CC BY 4.0

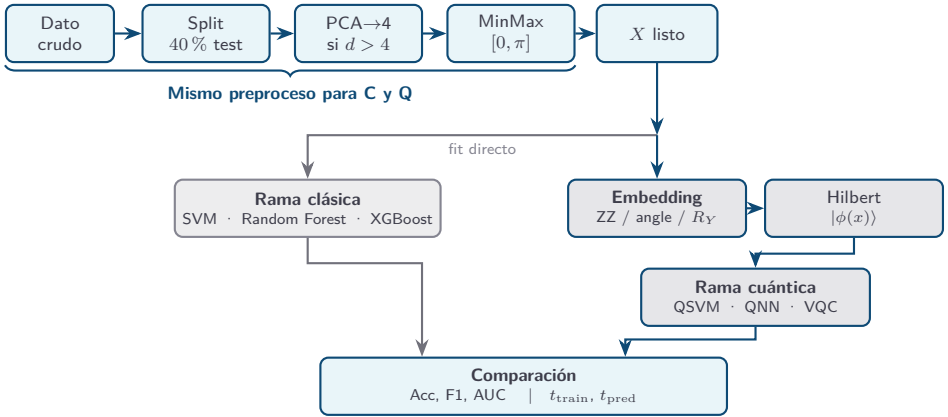
Kernels cuánticos: la ventaja depende de la geometría del dato frente al kernel (Havlíček et al., 2019; Huang et al., 2021; Schuld, 2021)

Variacionales: QAOA y VQE, limitados por barren plateaus (Farhi et al., 2014; Peruzzo et al., 2014; McClean et al., 2018)

Benchmarks: sin protocolo común, las comparaciones son asimétricas (Bowles et al., 2024; Yu et al., 2026)

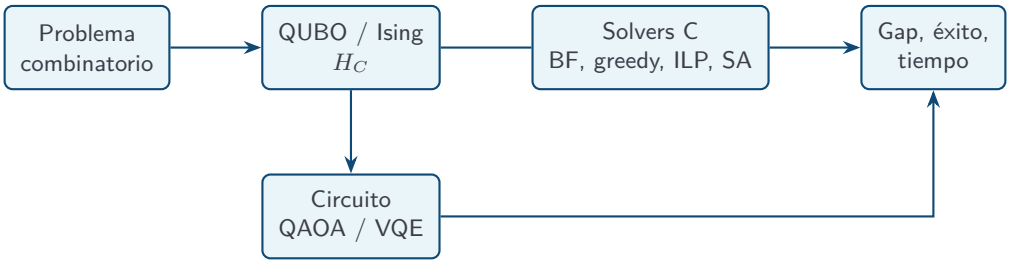
Resultados y análisis

Protocolo común en clasificación



El mismo X alimenta a los seis modelos; la rama cuántica añade el embedding en 4 qubits

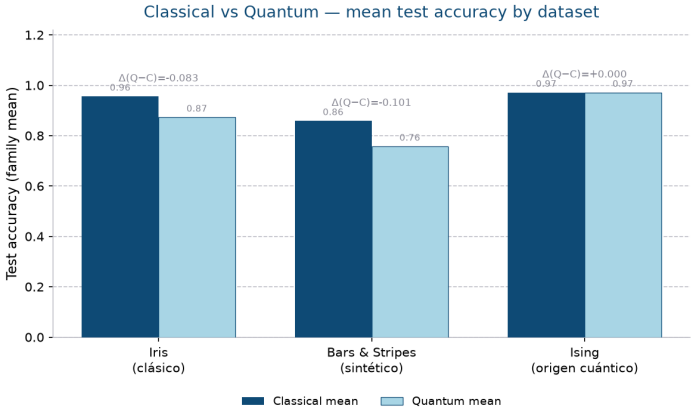
Resultados y análisis
Protocolo común en optimización



SA, QAOA y VQE minimizan el mismo H_C; simulación de estado con hasta 6 qubits

Resultados y análisis

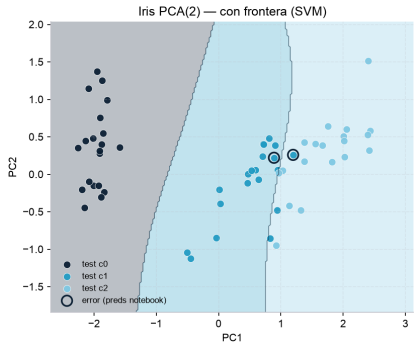
Clasificación: el cuántico solo empata en Ising



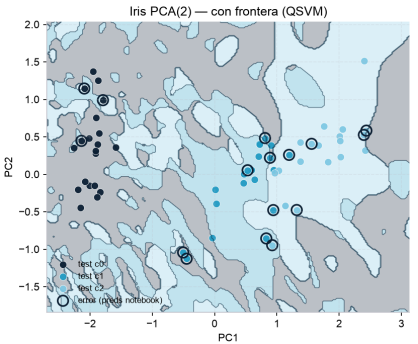
Ningún modelo cuántico supera al SVM-RBF en ningún dataset

Resultados y análisis

Iris: el mapa ZZ fragmenta la frontera



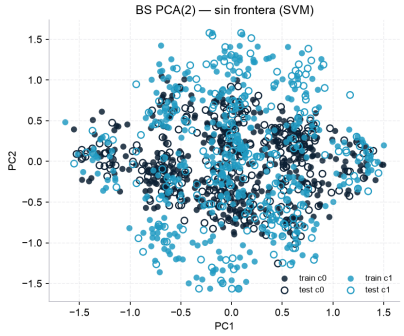
SVM-RBF: F1 0.967, 2 errores en el solapa

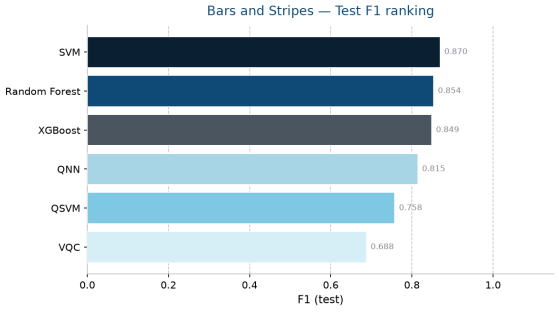


QSVM-ZZ: F1 0.730, 16 errores, también en setosa

QSVM: accuracy 0.967 en train y 0.733 en test, el mayor gap del corpus

Resultados y análisis
Bars and Stripes: clases solapadas, el VQC cae

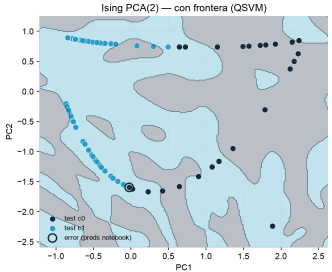




PCA a 4: 57.5 % de la varianza; clases solapadas

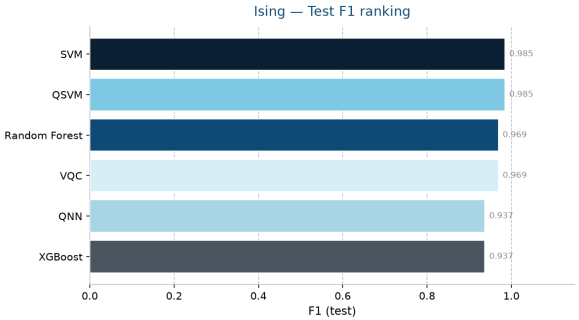
VQC: F1 0.688 y accuracy de train 0.710; no ajusta ni el train

Resultados y análisis
Ising: el dataset que todos resuelven



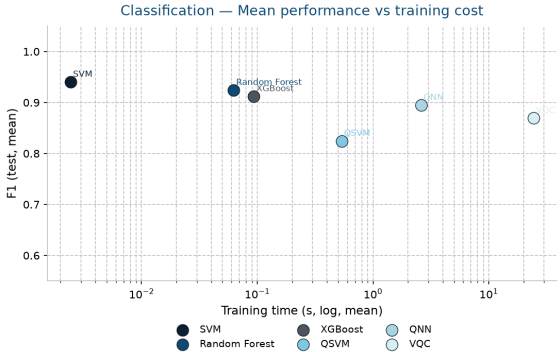
QSVM: 1 error de 80, con islas también aquí

El mapa ZZ actúa sobre la PCA de las amplitudes, no sobre los espines

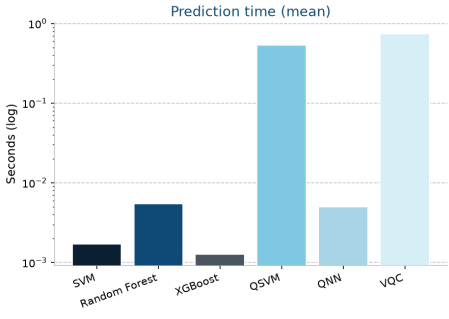


QSVM = SVM: F1 0.985, con los seis modelos en 0.95 de accuracy o más

Resultados y análisis
El coste de simular el circuito



F1 medio frente a tiempo medio de entrenamiento

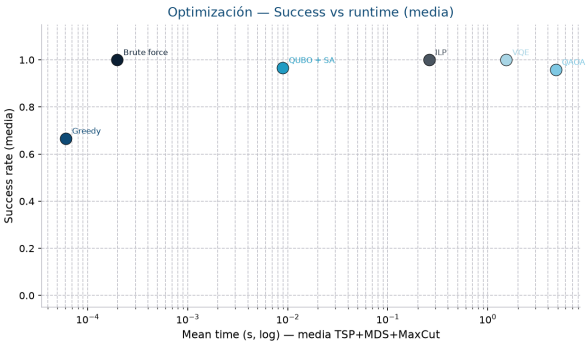


Tiempo medio de predicción

SVM: mejor F1 medio (0.940) en 2 ms. QSVM y VQC predicen de dos a tres órdenes más despacio

Resultados y análisis

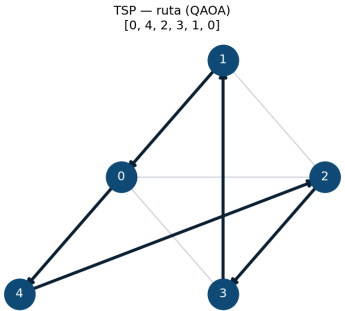
Optimización: casi todos llegan al óptimo, a distinto coste

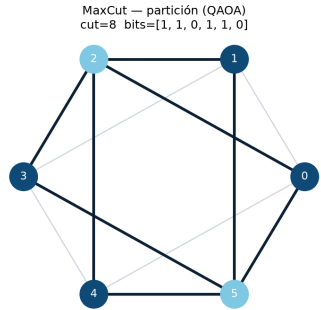


Éxito	TSP	MDS	MaxCut
Fuerza bruta	1	1	1
Greedy	1	**0**	1
ILP	1	1	1
QUBO + SA	0.9	1	1
QAOA	1	**0.875**	1
VQE	1	1	1

Fallan el greedy en MDS, SA en 2 de 20 semillas del TSP y QAOA en 1 de 8 del MDS

Resultados y análisis
TSP y MaxCut: QAOA reproduce el óptimo



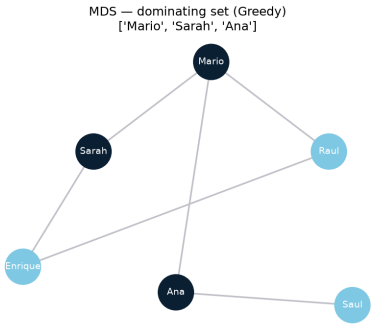


TSP: coste 16, el mejor bitstring de 3000 muestras

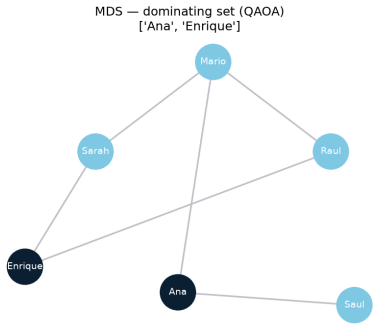
MaxCut: corte 8; P(corte óptimo) 0.93, uniforme 0.28

Mismo óptimo que la enumeración: 0.6–2 s de simulación frente a menos de 1 ms

Resultados y análisis
MDS: fallan el greedy y una semilla de QAOA



Greedy: tamaño 3, no óptimo



QAOA: óptimo en 7/8 semillas, P(óptimo) 0.53, 12.6 s

La semilla fallida devuelve un conjunto infactible; SA resuelve el mismo QUBO en 7 ms

Discusión: dónde hay paridad y dónde no

Paridad con el clásico

- Ising: QSVM $=$ SVM, con todos los modelos en 0.95 de accuracy o más
- TSP y MaxCut: QAOA y VQE reproducen $C^{\star}$, más lentos

Déficit o fallo

- Iris y BS: QSVM con F1 0.730 y 0.758, frente a 0.967 y 0.870 del SVM
- MDS: una semilla de QAOA termina en un conjunto infactible
- TSP y MDS: éxito leído del mejor de miles de muestras, no prueba concentración

Con $n \leq 6$ qubits se mide cercanía al clásico, no ventaja asintótica (Preskill, 2018; Thanasilp et al., 2024)

Conclusiones

1. **Sin ventaja en clasificación.** Los modelos clásicos igualan o superan a los cuánticos en todos los datasets
2. **Paridad solo en lo fácil.** El kernel cuántico empata donde todos aciertan y generaliza peor en datos convencionales
3. **Optimización sin mejora.** QAOA y VQE llegan al óptimo casi siempre, pero los métodos clásicos lo obtienen antes
4. **Régimen acotado.** Con pocos qubits simulados se mide cercanía al clásico, no ventaja

La paridad de calidad, cuando aparece, llega con un coste temporal mayor

Líneas futuras de investigación



Haug et al. (2023); Lloyd et al. (2020); Sentís et al. (2019); Bowles et al. (2024)

muchas gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

Referencias

Bowles, J., Ahmed, S., & Schuld, M. (2024). *Better than classical? The subtle art of benchmarking quantum machine learning models*. arXiv preprint arXiv:2403.07059. https://doi.org/10.48550/arXiv.2403.07059

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv preprint arXiv:1411.4028. https://doi.org/10.48550/arXiv.1411.4028

Haug, T., Self, C. N., & Kim, M. S. (2023). *Quantum machine learning of large datasets using randomized measurements*. Machine Learning: Science and Technology, 4(1), 015005. https://doi.org/10.1088/2632-2153/acb0b4

Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., & Gambetta, J. M. (2019). *Supervised learning with quantum-enhanced feature spaces*. Nature, 567(7747), 209–212. https://doi.org/10.1038/s41586-019-0980-2

Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., & McClean, J. R. (2021). *Power of data in quantum machine learning*. Nature Communications, 12(1), 2631. https://doi.org/10.1038/s41467-021-22539-9

Lloyd, S., Schuld, M., Ijaz, A., Izaac, J., & Killoran, N. (2020). *Quantum embeddings for machine learning*. arXiv preprint arXiv:2001.03622. https://doi.org/10.48550/arXiv.2001.03622

Lucas, A. (2014). *Ising formulations of many NP problems*. Frontiers in Physics, 2, 5. https://doi.org/10.3389/fphy.2014.00005

McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., & Neven, H. (2018). *Barren plateaus in quantum neural network training landscapes*. Nature Communications, 9(1), 4812. https://doi.org/10.1038/s41467-018-07090-4

Peruzzo, A., McClean, J., Shadbolt, P., Yung, M.-H., Zhou, X.-Q., Love, P. J., ... O'Brien, J. L. (2014). *A variational eigenvalue solver on a photonic quantum processor*. Nature Communications, 5(1), 4213. https://doi.org/10.1038/ncomms5213

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79. https://doi.org/10.22331/q-2018-08-06-79

Referencias

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv preprint arXiv:2101.11020. https://doi.org/10.48550/arXiv.2101.11020

Sentís, G., Monràs, A., Muñoz-Tapia, R., Calsamiglia, J., & Bagan, E. (2019). *Unsupervised classification of quantum data*. Physical Review X, 9(4), 041029. https://doi.org/10.1103/PhysRevX.9.041029

Thanasilp, S., Wang, S., Cerezo, M., & Holmes, Z. (2024). *Exponential concentration in quantum kernel methods*. Nature Communications, 15(1), 5200. https://doi.org/10.1038/s41467-024-49287-w

Yu, C., Liu, J., Ge, Z., Wu, X., Zhu, L., Zhao, P., & Zhao, J. (2026). *Quantum vs. classical machine learning: A unified empirical comparison*. arXiv preprint arXiv:2607.01197. https://doi.org/10.48550/arXiv.2607.01197