La Evolución de la Ciencia de Datos hacia la Computación Cuántica: Análisis de la Ventaja Cuántica en Casos Aplicados

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón

Máster en Computación Cuántica · UNIR

Director: Ricardo Rafael Domínguez Reyes

unir LA UNIVERSIDAD EN INTERNET

ÍNDICE

01 – Introducción

02 – Motivación

03 – Objetivos

04 – Contexto y estado de la técnica

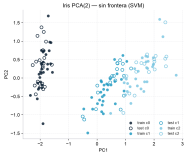
05 – Resultados y análisis

06 – Conclusiones

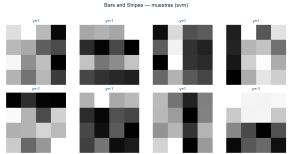
07 – Líneas futuras de investigación

Introducción
Dos familias de problemas, seis datasets

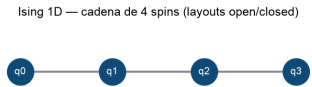
¿Mejoran los métodos cuánticos, simulados con pocos qubits, la calidad o el coste frente a los clásicos?



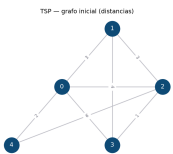
Iris: dato convencional



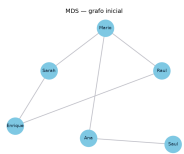
Bars and Stripes: patrones 4×4



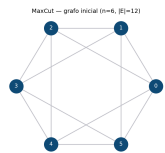
Ising: dato de sistema



TSP: 5 nodos

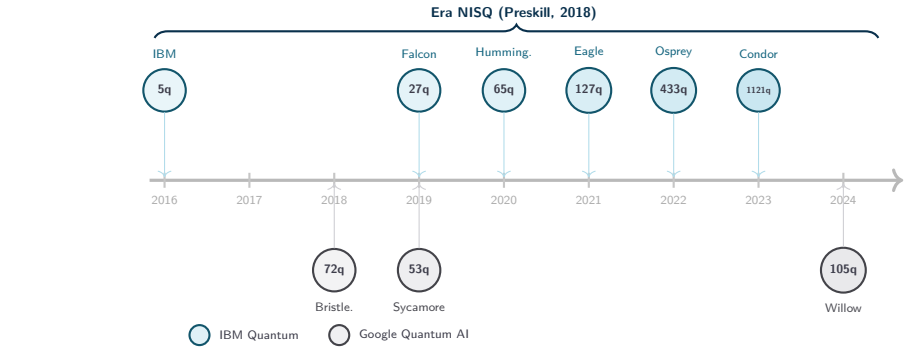


MDS: 6 vértices



MaxCut (HamLib): 6 vértices

Motivación
Mucha promesa, poca evidencia comparable



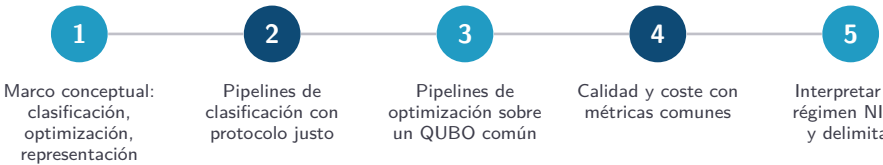
Promesa: kernels en espacios de Hilbert grandes y QAOA/VQE en hardware NISQ (Havlíček et al., 2019; Farhi et al., 2014)

Evidencia: con protocolo justo, los clásicos suelen igualar o ganar (Bowles et al., 2024; Yu et al., 2026)

Objetivos

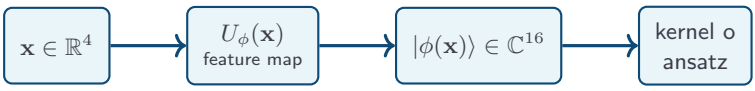
Objetivo general

Evaluar de forma empírica si los algoritmos cuánticos NISQ ofrecen ventaja medible frente a los clásicos en clasificación y optimización.

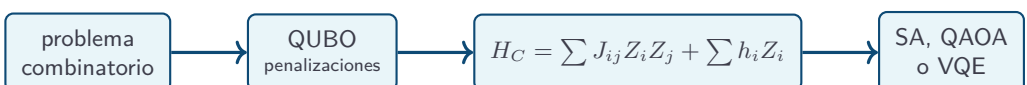


Contexto y estado de la técnica
La representación como puente

Clasificación



Optimización



El feature map y el QUBO fijan el espacio en el que opera el método cuántico (Lloyd et al., 2020; Lucas, 2014).

Contexto y estado de la técnica
Estado de la técnica

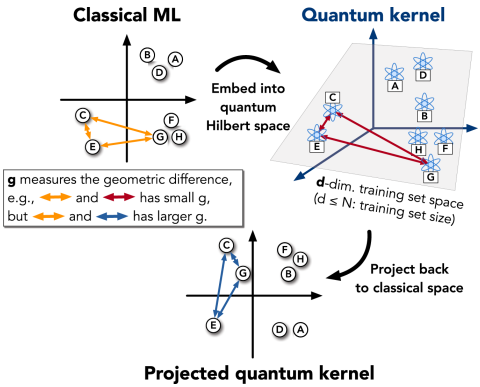


Fig. 2 de Huang et al. (2021), CC BY 4.0

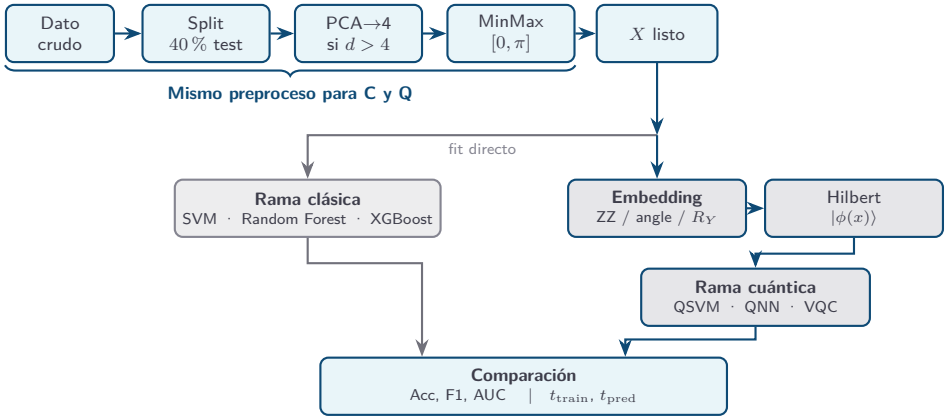
Kernels cuánticos: la ventaja depende de la geometría del dato frente al kernel (Havlíček et al., 2019; Huang et al., 2021; Schuld, 2021)

Variacionales: QAOA y VQE, limitados por barren plateaus (Farhi et al., 2014; Peruzzo et al., 2014; McClean et al., 2018)

Benchmarks: sin protocolo común, las comparaciones son asimétricas (Bowles et al., 2024; Yu et al., 2026)

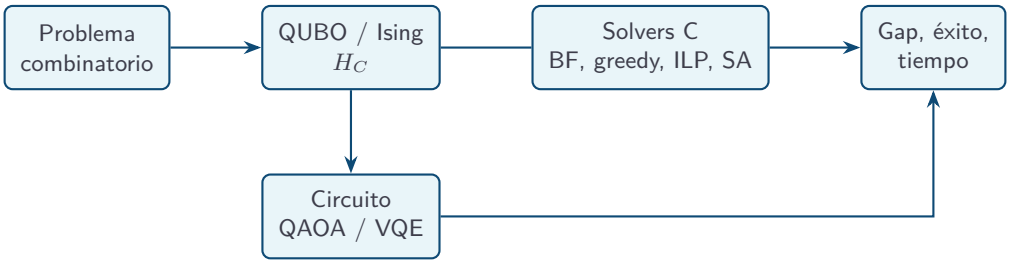
Resultados y análisis

Protocolo común en clasificación



El mismo X alimenta a los seis modelos; la rama cuántica añade el embedding en 4 qubits

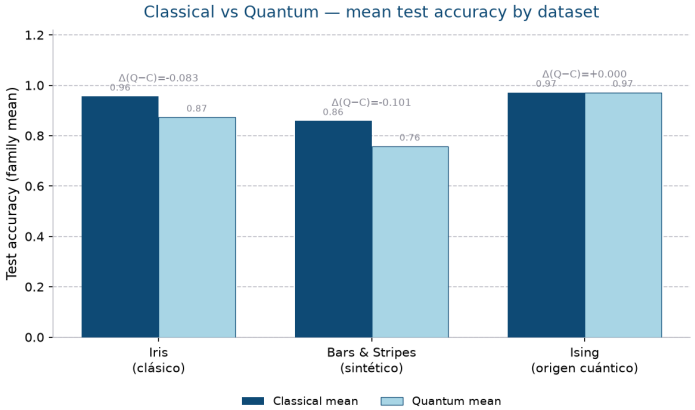
Resultados y análisis
Protocolo común en optimización



SA, QAOA y VQE minimizan el mismo H_C; simulación de estado con hasta 6 qubits

Resultados y análisis

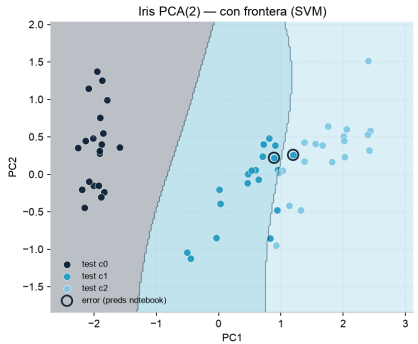
Clasificación: el cuántico solo empata en Ising



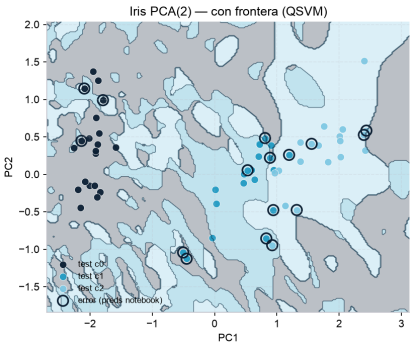
Ningún modelo cuántico supera al SVM-RBF en ningún dataset

Resultados y análisis

Iris: el mapa ZZ fragmenta la frontera



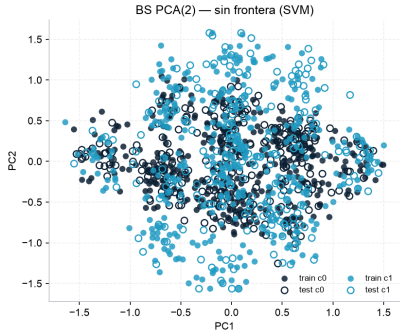
SVM-RBF: F1 0.967, 2 errores en el solapa

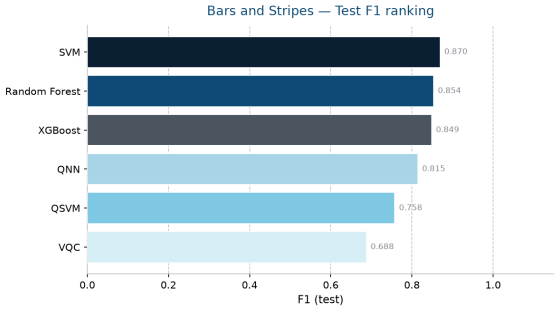


QSVM-ZZ: F1 0.730, 16 errores, también en setosa

QSVM: accuracy 0.967 en train y 0.733 en test, el mayor gap del corpus

Resultados y análisis
Bars and Stripes: clases solapadas, el VQC cae

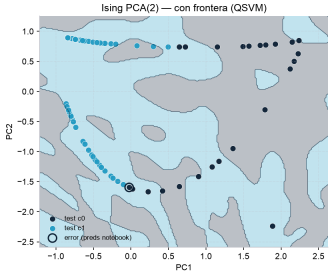




PCA a 4: 57.5 % de la varianza; clases solapadas

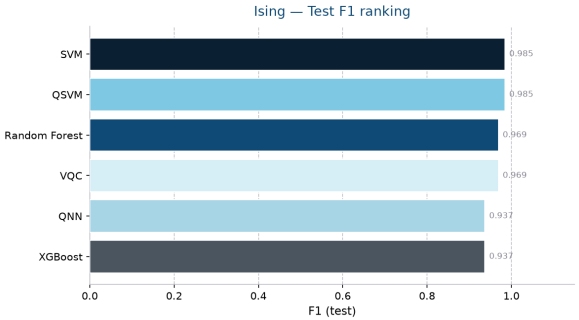
VQC: F1 0.688 y accuracy de train 0.710; no ajusta ni el train

Resultados y análisis
Ising: el dataset que todos resuelven



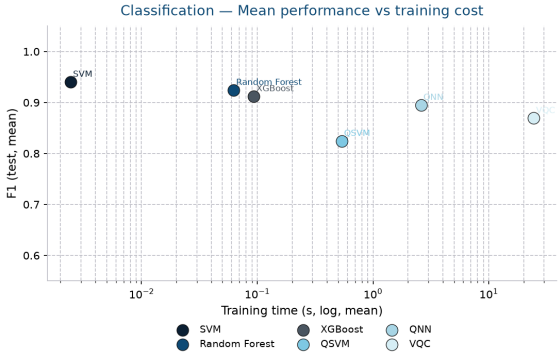
QSVM: 1 error de 80, con islas también aquí

El mapa ZZ actúa sobre la PCA de las amplitudes, no sobre los espines

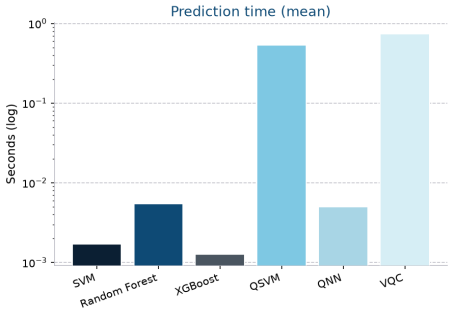


QSVM = SVM: F1 0.985, con los seis modelos en 0.95 de accuracy o más

Resultados y análisis
El coste de simular el circuito



F1 medio frente a tiempo medio de entrenamiento

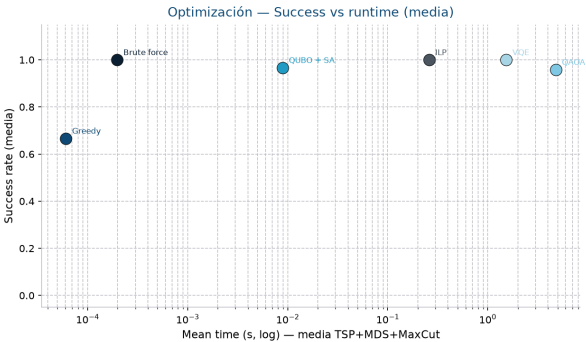


Tiempo medio de predicción

SVM: mejor F1 medio (0.940) en 2 ms. QSVM y VQC predicen de dos a tres órdenes más despacio

Resultados y análisis

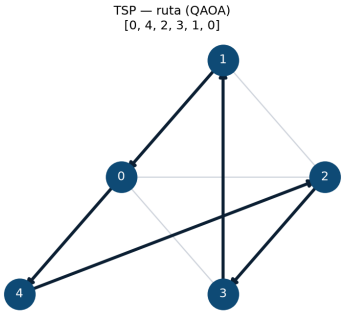
Optimización: casi todos llegan al óptimo, a distinto coste

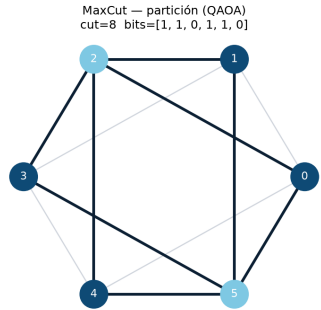


Éxito	TSP	MDS	MaxCut
Fuerza bruta	1	1	1
Greedy	1	**0**	1
ILP	1	1	1
QUBO + SA	0.9	1	1
QAOA	1	**0.875**	1
VQE	1	1	1

Fallan el greedy en MDS, SA en 2 de 20 semillas del TSP y QAOA en 1 de 8 del MDS

Resultados y análisis
TSP y MaxCut: QAOA reproduce el óptimo



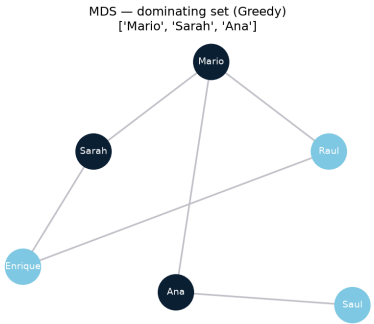


TSP: coste 16, el mejor bitstring de 3000 muestras

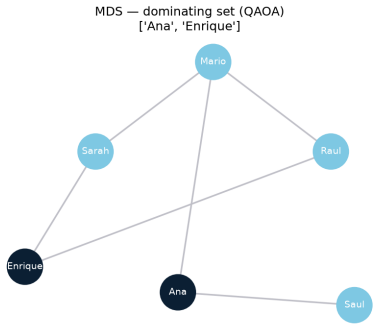
MaxCut: corte 8; P(corte óptimo) 0.93, uniforme 0.28

Mismo óptimo que la enumeración: 0.6–2 s de simulación frente a menos de 1 ms

Resultados y análisis
MDS: fallan el greedy y una semilla de QAOA



Greedy: tamaño 3, no óptimo



QAOA: óptimo en 7/8 semillas, P(óptimo) 0.53, 12.6 s

La semilla fallida devuelve un conjunto infactible; SA resuelve el mismo QUBO en 7 ms

Discusión: dónde hay paridad y dónde no

Paridad con el clásico

- Ising: QSVM $=$ SVM, con todos los modelos en 0.95 de accuracy o más
- TSP y MaxCut: QAOA y VQE reproducen $C^{\star}$, más lentos

Déficit o fallo

- Iris y BS: QSVM con F1 0.730 y 0.758, frente a 0.967 y 0.870 del SVM
- MDS: una semilla de QAOA termina en un conjunto infactible
- TSP y MDS: éxito leído del mejor de miles de muestras, no prueba concentración

Con $n \leq 6$ qubits se mide cercanía al clásico, no ventaja asintótica (Preskill, 2018; Thanasilp et al., 2024)

Conclusiones

1. **Sin ventaja en clasificación.** SVM-RBF mejor o empatado en los tres datasets

2. **ZZ solo empata en Ising.** El dataset en el que todos alcanzan 0.95 de accuracy

3. **Optimización sin mejora.** QAOA y VQE tardan 0.6–12.6 s por ejecución; la enumeración, < 1 ms

4. **Régimen acotado.** 4–6 qubits simulados: cercanía, no ventaja

La paridad de calidad, cuando aparece, llega con un coste temporal mayor

Líneas futuras de investigación



Haug et al. (2023); Lloyd et al. (2020); Sentís et al. (2019); Bowles et al. (2024)

muchas gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

Referencias

Bowles, J., Ahmed, S., & Schuld, M. (2024). *Better than classical? The subtle art of benchmarking quantum machine learning models*. arXiv preprint arXiv:2403.07059. https://doi.org/10.48550/arXiv.2403.07059

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv preprint arXiv:1411.4028. https://doi.org/10.48550/arXiv.1411.4028

Haug, T., Self, C. N., & Kim, M. S. (2023). *Quantum machine learning of large datasets using randomized measurements*. Machine Learning: Science and Technology, 4(1), 015005. https://doi.org/10.1088/2632-2153/acb0b4

Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., & Gambetta, J. M. (2019). *Supervised learning with quantum-enhanced feature spaces*. Nature, 567(7747), 209–212. https://doi.org/10.1038/s41586-019-0980-2

Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., & McClean, J. R. (2021). *Power of data in quantum machine learning*. Nature Communications, 12(1), 2631. https://doi.org/10.1038/s41467-021-22539-9

Lloyd, S., Schuld, M., Ijaz, A., Izaac, J., & Killoran, N. (2020). *Quantum embeddings for machine learning*. arXiv preprint arXiv:2001.03622. https://doi.org/10.48550/arXiv.2001.03622

Lucas, A. (2014). *Ising formulations of many NP problems*. Frontiers in Physics, 2, 5. https://doi.org/10.3389/fphy.2014.00005

McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., & Neven, H. (2018). *Barren plateaus in quantum neural network training landscapes*. Nature Communications, 9(1), 4812. https://doi.org/10.1038/s41467-018-07090-4

Peruzzo, A., McClean, J., Shadbolt, P., Yung, M.-H., Zhou, X.-Q., Love, P. J., ... O'Brien, J. L. (2014). *A variational eigenvalue solver on a photonic quantum processor*. Nature Communications, 5(1), 4213. https://doi.org/10.1038/ncomms5213

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79. https://doi.org/10.22331/q-2018-08-06-79

Referencias

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv preprint arXiv:2101.11020. https://doi.org/10.48550/arXiv.2101.11020

Sentís, G., Monràs, A., Muñoz-Tapia, R., Calsamiglia, J., & Bagan, E. (2019). *Unsupervised classification of quantum data*. Physical Review X, 9(4), 041029. https://doi.org/10.1103/PhysRevX.9.041029

Thanasilp, S., Wang, S., Cerezo, M., & Holmes, Z. (2024). *Exponential concentration in quantum kernel methods*. Nature Communications, 15(1), 5200. https://doi.org/10.1038/s41467-024-49287-w

Yu, C., Liu, J., Ge, Z., Wu, X., Zhu, L., Zhao, P., & Zhao, J. (2026). *Quantum vs. classical machine learning: A unified empirical comparison*. arXiv preprint arXiv:2607.01197. https://doi.org/10.48550/arXiv.2607.01197