Ventaja cuántica en ciencia de datos: clasificación, optimización y representación en régimen NISQ

Defensa del Trabajo de Fin de Máster

Juan David Prada Malagón
Máster en Computación Cuántica · UNIR
Director: Ricardo Rafael Domínguez Reyes

unir LA UNIVERSIDAD EN INTERNET

ÍNDICE

01 – Introducción

02 – Motivación

03 – Objetivos

04 – Contexto y estado de la técnica

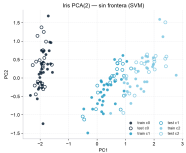
05 – Resultados y análisis

06 – Conclusiones

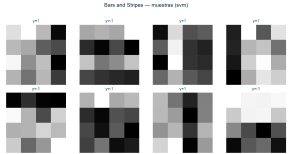
07 – Trabajo futuro

Introducción
Seis problemas, un mismo protocolo

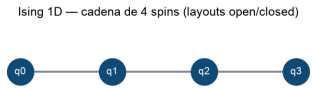
¿Mejoran los métodos cuánticos, simulados con pocos qubits, la calidad o el coste frente a los clásicos?



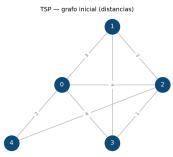
Iris: dato convencional



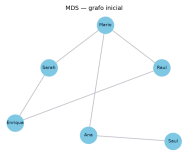
Bars and Stripes: patrones 4×4



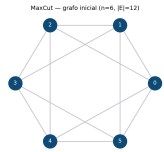
Ising: dato de sistema



TSP: 5 nodos

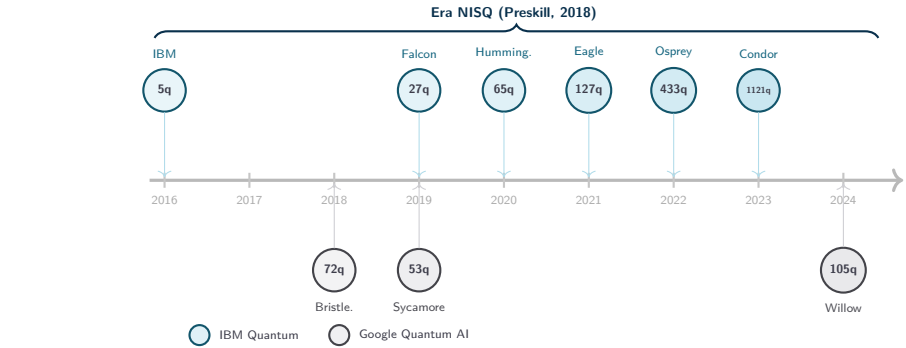


MDS: 6 vértices



MaxCut (HamLib): 6 vértices

Motivación
Mucha promesa, poca evidencia comparable



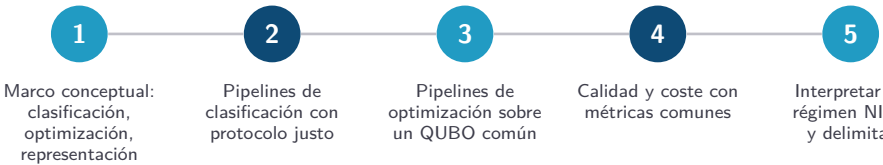
Promesa: kernels en espacios de Hilbert grandes y QAOA/VQE en hardware NISQ (Havlíček et al., 2019; Farhi et al., 2014)

Evidencia: con protocolo justo, los clásicos suelen igualar o ganar (Bowles et al., 2024; Yu et al., 2026)

Objetivos

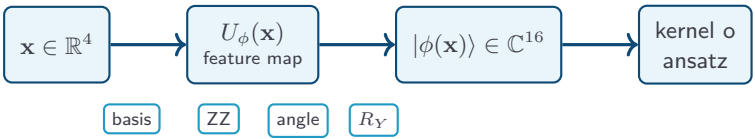
Objetivo general

Evaluar de forma empírica si los algoritmos cuánticos NISQ ofrecen ventaja medible frente a los clásicos en clasificación y optimización.

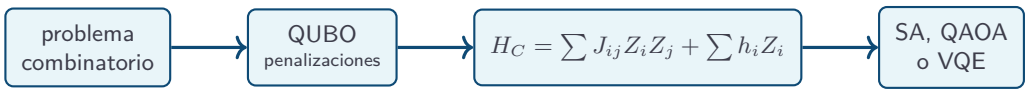


Contexto y estado de la técnica
La representación como puente

Clasificación



Optimización



El espacio donde se resuelve el problema decide qué estructura puede explotar el algoritmo (Lloyd et al., 2020; Lucas, 2014).

Contexto y estado de la técnica
Estado de la técnica

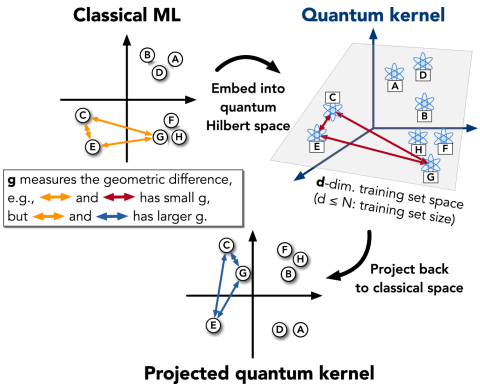


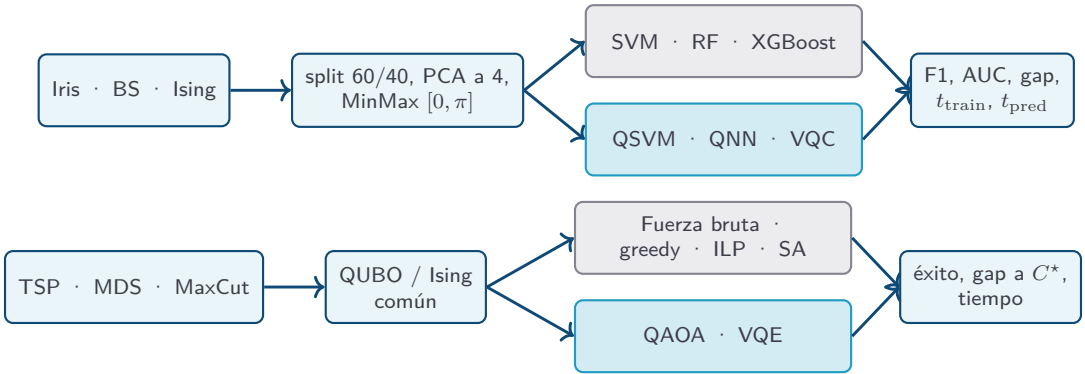
Fig. 2 de Huang et al. (2021), CC BY 4.0

Kernels cuánticos: la ventaja depende de la geometría del dato frente al kernel (Havlíček et al., 2019; Huang et al., 2021; Schuld, 2021)

Variacionales: QAOA y VQE, limitados por barren plateaus (Farhi et al., 2014; Peruzzo et al., 2014; McClean et al., 2018)

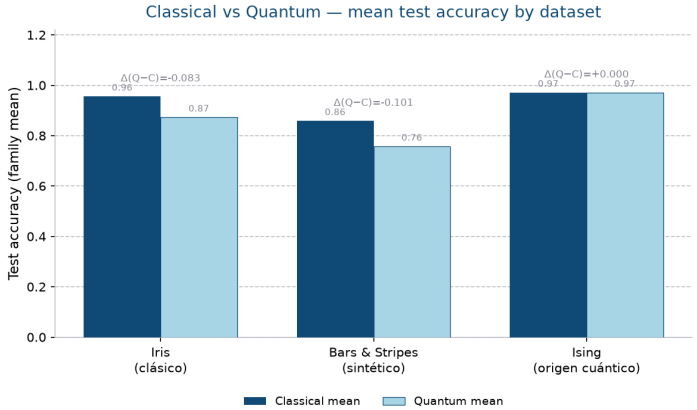
Benchmarks: sin protocolo común, las comparaciones son asimétricas (Bowles et al., 2024; Yu et al., 2026)

Resultados y análisis
Protocolo común



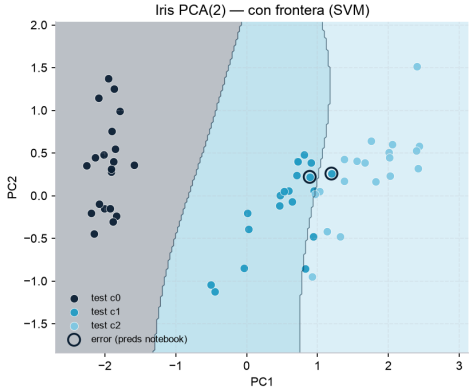
Simulación de estado sobre CPU: 4 qubits en clasificación, hasta 6 en optimización

Resultados y análisis
Clasificación: el cuántico solo empata en Ising

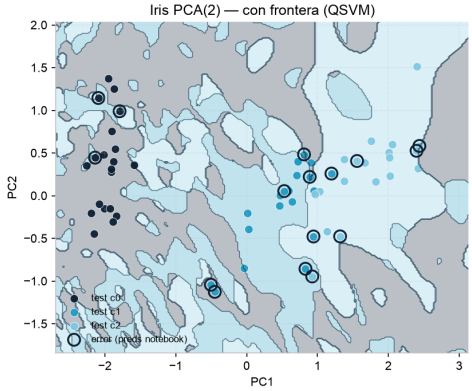


Media de la familia: $-0{,}083$ en Iris, $-0{,}101$ en Bars and Stripes, $0{,}000$ en Ising

Resultados y análisis
Iris: el mapa ZZ fragmenta la frontera



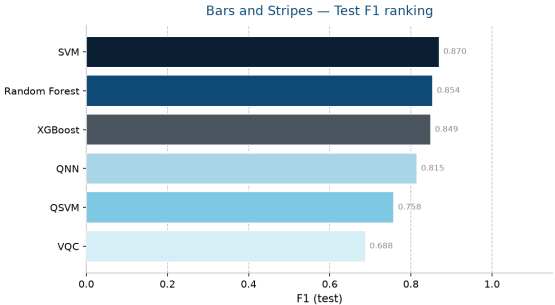
SVM-RBF: F1 0.967

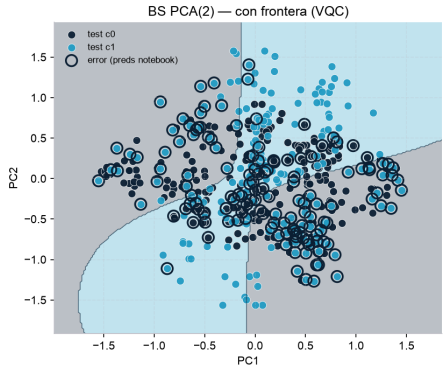


QSVM-ZZ: F1 0.730

Resultados y análisis

Bars and Stripes: nube mezclada, el VQC cae

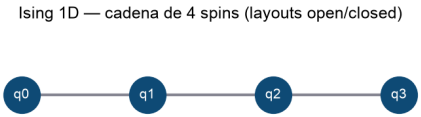




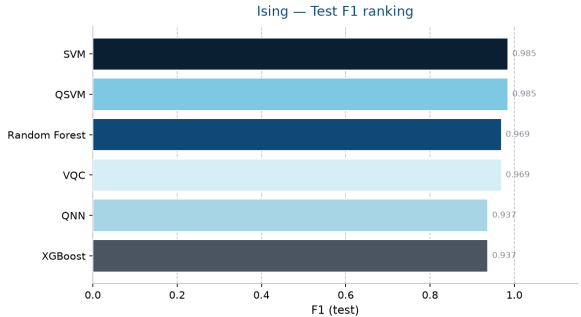
VQC: F1 0.688, el peor del dataset

Resultados y análisis

Ising: el mapa comparte estructura con el dato

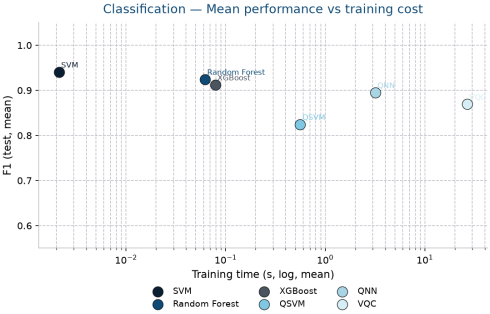


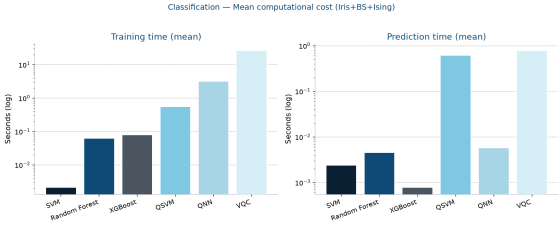
Hamiltoniano con términos $Z_i Z_{i+1}$,
los mismos que entrelaza el mapa ZZ



QSVM = SVM: F1 0.985. Única paridad cuántica del corpus

Resultados y análisis
El coste de simular el circuito

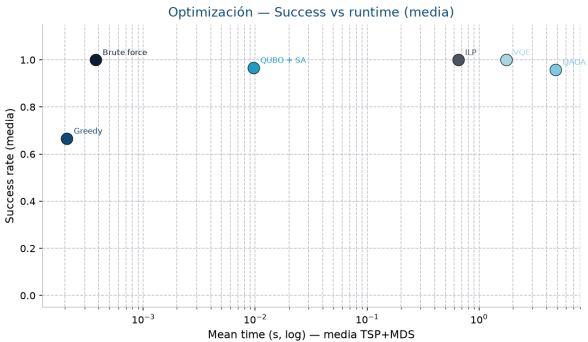




SVM: mejor F1 en milisegundos. VQC: decenas de segundos sin mejorar la calidad

Resultados y análisis

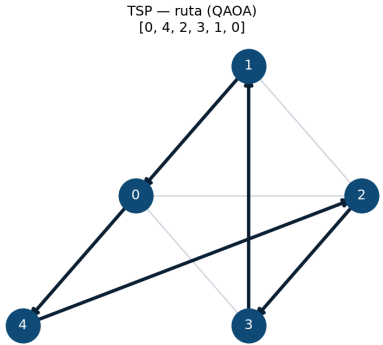
Optimización: todos llegan al óptimo, a distinto coste



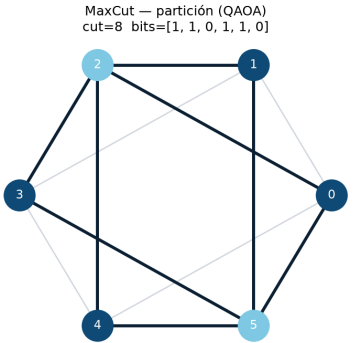
Éxito	TSP	MDS	MaxCut
Fuerza bruta	1	1	1
Greedy	1	**0**	1
ILP	1	1	1
QUBO + SA	0.9	1	1
QAOA	1	**0.875**	1
VQE	1	1	1

Resultados y análisis

TSP y MaxCut: QAOA reproduce el óptimo



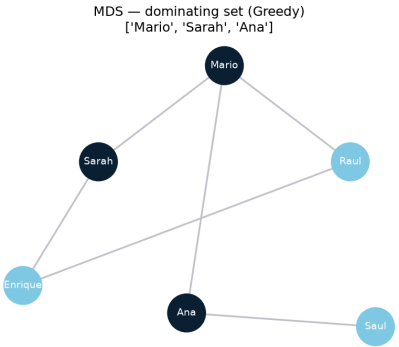
TSP: ruta óptima, coste 16



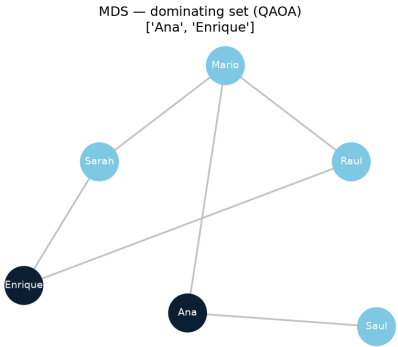
MaxCut: corte óptimo 8

Mismo óptimo que la enumeración, con 1–2 s de simulación frente a milisegundos

Resultados y análisis
MDS: las penalizaciones cuestan



Greedy: tamaño 3, no óptimo



QAOA: tamaño 2, éxito 0.875 sobre semillas

SA resuelve el mismo QUBO: la dificultad está en optimizar el ansatz, no en la formulación

Discusión: la representación como eje

Representación alineada

- Ising + mapa ZZ: paridad con el SVM
- MaxCut: H_C es el corte, sin penalizaciones

Representación no alineada

- Iris y BS + mapa ZZ: frontera fragmentada
- MDS: penalizaciones que el ansatz no concentra

Con $n \leq 6$ qubits se mide cercanía al clásico, no ventaja asintótica (Preskill, 2018; Thanasilp et al., 2024)

Conclusiones

1. **Sin ventaja en clasificación.** SVM-RBF mejor o empatado en los tres datasets
2. **Decide el feature map.** ZZ solo empata donde comparte estructura con el dato
3. **Optimización sin mejora.** QAOA y VQE reproducen $C^\star$ con más coste
4. **Régimen acotado.** 4–6 qubits simulados: cercanía, no ventaja

Cualquier ventaja exige una representación alineada con la estructura del problema

Trabajo futuro

Escala
cadenas de Ising de 6–12 espines

QUBO mayores
QAOA con $p > 1$ frente a SA

Hardware real
shots y mitigación de errores

Representación
basis encoding y embeddings entrenables

Entrenabilidad
barren plateaus e hiperparámetros

Otras familias
regresión y clustering

Zhou et al. (2020); Haug et al. (2023); Lloyd et al. (2020); McClean et al. (2018); Sentís et al. (2019)

muchas gracias

¿Preguntas?

Juan David Prada Malagón · UNIR

Referencias

Bowles, J., Ahmed, S., & Schuld, M. (2024). *Better than classical? The subtle art of benchmarking quantum machine learning models*. arXiv preprint arXiv:2403.07059. https://doi.org/10.48550/arXiv.2403.07059

Farhi, E., Goldstone, J., & Gutmann, S. (2014). *A quantum approximate optimization algorithm*. arXiv preprint arXiv:1411.4028. https://doi.org/10.48550/arXiv.1411.4028

Haug, T., Self, C. N., & Kim, M. S. (2023). *Quantum machine learning of large datasets using randomized measurements*. Machine Learning: Science and Technology, 4(1), 015005. https://doi.org/10.1088/2632-2153/acb0b4

Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., & Gambetta, J. M. (2019). *Supervised learning with quantum-enhanced feature spaces*. Nature, 567(7747), 209–212. https://doi.org/10.1038/s41586-019-0980-2

Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., & McClean, J. R. (2021). *Power of data in quantum machine learning*. Nature Communications, 12(1), 2631. https://doi.org/10.1038/s41467-021-22539-9

Lloyd, S., Schuld, M., Ijaz, A., Izaac, J., & Killoran, N. (2020). *Quantum embeddings for machine learning*. arXiv preprint arXiv:2001.03622. https://doi.org/10.48550/arXiv.2001.03622

Lucas, A. (2014). *Ising formulations of many NP problems*. Frontiers in Physics, 2, 5. https://doi.org/10.3389/fphy.2014.00005

McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., & Neven, H. (2018). *Barren plateaus in quantum neural network training landscapes*. Nature Communications, 9(1), 4812. https://doi.org/10.1038/s41467-018-07090-4

Peruzzo, A., McClean, J., Shadbolt, P., Yung, M.-H., Zhou, X.-Q., Love, P. J., ... O'Brien, J. L. (2014). *A variational eigenvalue solver on a photonic quantum processor*. Nature Communications, 5(1), 4213. https://doi.org/10.1038/ncomms5213

Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79. https://doi.org/10.22331/q-2018-08-06-79

Referencias

Schuld, M. (2021). *Supervised quantum machine learning models are kernel methods*. arXiv preprint arXiv:2101.11020. https://doi.org/10.48550/arXiv.2101.11020

Sentís, G., Monràs, A., Muñoz-Tapia, R., Calsamiglia, J., & Bagan, E. (2019). *Unsupervised classification of quantum data*. Physical Review X, 9(4), 041029. https://doi.org/10.1103/PhysRevX.9.041029

Thanasilp, S., Wang, S., Cerezo, M., & Holmes, Z. (2024). *Exponential concentration in quantum kernel methods*. Nature Communications, 15(1), 5200. https://doi.org/10.1038/s41467-024-49287-w

Yu, C., Liu, J., Ge, Z., Wu, X., Zhu, L., Zhao, P., & Zhao, J. (2026). *Quantum vs. classical machine learning: A unified empirical comparison*. arXiv preprint arXiv:2607.01197. https://doi.org/10.48550/arXiv.2607.01197

Zhou, L., Wang, S.-T., Choi, S., Pichler, H., & Lukin, M. D. (2020). *Quantum approximate optimization algorithm: Performance, mechanism, and implementation on near-term devices*. Physical Review X, 10(2), 021067. https://doi.org/10.1103/PhysRevX.10.021067